# A prediction model of PM2.5 in Central Taiwan

Yu-Chen Lai

Master's Thesis
Institute of Statistics
National Chung Hsing University, Taichung, Taiwan
July 2016

Advisors: Yu-Pin Hu and Hong-Dar Wu
Oral defense committee: Zong-Yi Lin

Case study: Dali air quality station, Taichung. Main text in Chinese.
DOI: 10.5281/zenodo.15343809 Handle: https://hdl.handle.net/11296/93x74z
License: CC BY 4.0

# Abstract

Due to the growing concern over the health risks posed by air pollution, this study focuses on developing an accurate prediction model for PM2.5 concentration in Central Taiwan. The core objective is to identify the most effective variable selection methods that minimize forecasting errors. This research utilizes recursive updating forecasts to generate predictive values and compares the performance of three variable selection criteria: Akaike Information Criterion (AIC), Bayesian Information Criterion (BIC), and Orthogonal Greedy Algorithm (OGA).

The model is validated using both real and simulated datasets. The simulations are conducted via the Parametric Bootstrap Method to repeatedly generate parameterized observations. The model performance is assessed using mean squared error (MSE) across 500 iterations. The results indicate that OGA often achieves the lowest MSE and outperforms AIC and BIC in predictive accuracy, although BIC selects fewer variables. Notably, some seemingly irrelevant variables, when included in the model, contribute to improved forecasts, suggesting further research potential.



*Keywords:* PM2.5; air pollution; variable selection; Orthogonal Greedy Algorithm (OGA); AIC; BIC; recursive updating forecast; parametric bootstrap; statistical forecasting

國立中興大學統計學研究所
碩士學位論文

# 台灣中部地區 $PM_{2.5}$ 的預測模型-以大里為例

A prediction model of $PM_{2.5}$ in Central Taiwan

國立中興大學
National Chung Hsing University

指導教授：胡毓彬 Dr.Yu-Pin Hu
吳宏達 Dr.Hong-Da Wu
研 究 生：賴昱辰 Yu-Chen Lai

中華民國一〇五年六月

## 摘要

有鑑於人們逐漸發現空氣汙染對健康的危害，本篇論文的研究目的將著重於如何預測明日的 $PM_{2.5}$、選擇有效的估計變數、以及降低預測誤差。首先使用訓練組資料透過逐步更新預測法 (recursive updating forecast) 求出預測資料，逐步遞移得到所有預測值並求得其均方誤差，比較三種變數選擇的表現，這三種變數選擇法主要包含 AIC、BIC 及正交貪婪演算法 (OGA)。

接著運用在真實資料中使用正交貪婪演算法之變數選擇結果，採用均方誤差第一次達到低點的變數組合，設定迴歸模型，建立殘差矩陣並使用模型中的參數執行有母數拔靴法 (Parameteric Bootstrap Method)，模擬出所有的真實變數，觀察當加入與假設真實模型無關的變數時預測誤差的變化，以及三種變數選擇之結果。其結果顯示 BIC 擁有最少的變數選擇個數，而相較於以 AIC 或 BIC 為選擇標準，使用正交貪婪演算法在大部分的情況下均方誤差較低，而某些與假設真實模型無關的變數，在加入模型後卻能使預測誤差降低，值得未來進一步的探討。



關鍵字：正交貪婪演算法 (Orthogonal Greedy Algorithm)、逐步更新預測法 (Recursive Updating Forecasts)、AIC、BIC、有母數拔靴法 (Parameteric Bootstrap Method)



國立中興大學 National Chung Hsing University

**Abstract**

In view of people found the health hazards from air pollution gradually, this thesis focus on how to estimate tomorrow's $PM_{2.5}$、choose the efficiency estimators and reduce the prediction error. First, we using training data to get prediction data by recursive updating forecast, then calculating the mean sqared error(MSE), comparing the performance in three kinds of variable selection criteria by their mean sqared error, these methods are included AIC, BIC and OGA.

Then, ultilizing the variable combination by using OGA in real data which is reached the first lowest MSE, setting the regression model, building residual matrix , generateing the data and implementing simulation test by parameteric bootstrap method. The results show that BIC has the fewest number of variables, but there is a better perdiction way by using Orthogonal Greedy Algorithm as selection criterion in most cases than using step regression with AIC/BIC criterion, and there is a better prediction result when putting in some unrelated variables with the model, it worth further research in the future.

國立中興大學
National Chung Hsing University

*Key words:* Orthogonal Greedy Algorithm、Recursive Updating Forecasts、AIC、BIC、Parametric Bootstrap Method

# 謝誌

還記得當年準備退伍時，與家人經過一番討論決定繼續升學準備研究所，那段歲月，彷彿歷歷在目；而在本篇論文完稿之際，也將是中興大學統研所的研究生涯畫上句點的時刻，兩年光陰，轉眼即逝。這兩年的學生旅程，恩師 吳宏達教授展現了一種身為統計人的風骨，一起探討如何處理資料、研究方法、奇思妙想，總讓學生如沐春風，記得老師總愛告訴學生:「怎敢憑一把鏽劍，就想闖蕩江湖。」這句話總提醒著學生砥礪精進，虛懷若谷。在論文的研究過程中，總會遇到許多的跌磕，常常一盞桌燈思索到深夜依舊毫無頭緒，所幸有恩師的摯友 胡毓彬教授，千里迢迢從南投到來一同與我們討論，有時甚至透過電話指導學生，使得問題總能迎刃而解，此番恩情，學生銘記在心。

而在我背後一路默默支持著我的母親、老婆、岳父岳母，你們對我的愛都化作了源源不絕的動力，讓我能不斷朝著更好的未來邁進，謝謝。如果有人問我這輩子最珍貴的是甚麼？我想答案就是你們。

最後謹以此篇謝誌獻給所有幫助過我的人。

賴昱辰 謹誌

國立中興大學統計研究所

中華民國一百零五年六月

# 目錄

**1 緒論** **1**

**2 文獻回顧** **3**

2.1 預測模型 . . . . . 3

2.2 Akaike 訊息判據 (Akaike information criterion; AIC) . . . . . 4

2.3 貝氏訊息判據 (Bayesian information criterion; BIC) . . . . . 5

2.4 正交貪婪法 (orthogonal greedy algorithm; OGA) . . . . . 7

2.5 有母數拔靴法 (parametric bootstrap method) . . . . . 8

**3 預測模型建立** **12**

3.1 資料結構 . . . . . 12

3.2 變數選擇 . . . . . 12

3.2.1 使用變數 . . . . . 12

3.2.2 挑選變數 . . . . . 14

3.3 預測結果判斷標準 . . . . . 15

3.4 預測結果 . . . . . 17

**4 模擬研究** **22**

4.1 假設 . . . . . 22

4.2 目的 . . . . . 22

4.3 生成資料 . . . . . 23

4.4 模擬結果 . . . . . 30

**5 結論** **33**

國立中興大學 National Chung Hsing University

# 圖目次


1 抽菸比例與肺癌發生率對照圖 (資料來源：衛生福利部)。 . . . . . 1
2 大里 2011 到 2014 之 $PM_{2.5}$ 趨勢圖。 . . . . . 13
3 均方誤差隨著變數增加之變化情形。 . . . . . 17
4 真實值、預測值、取完絕對值之預測誤差 . . . . . 18
5 是否降雨之預測誤差 . . . . . 18
6 依星期分類後之預測誤差 . . . . . 19
7 依月份分類後之預測誤差 . . . . . 19
8 透過 OGA 法逐步選擇變數時，均方誤差之變化情形 . . . . . 22
9 隨機抽出 AR(1) 變數之 acf 與 pacf 圖。 . . . . . 26
10 隨機抽出 AR(2) 變數之 acf 與 pacf 圖。 . . . . . 26
11 隨機抽出 AR(7) 變數之 acf 與 pacf 圖。 . . . . . 29
12 隨機抽出 AR(10) 變數之 acf 與 pacf 圖。 . . . . . 29
13 三種方法之均方誤差之排名。 . . . . . 30
14 三種方法均方誤差低於基準均方誤差之次數。 . . . . . 31
15 三種方法選擇之變數個數。 . . . . . 32


國立中興大學 National Chung Hsing University

# 表目次


1 使用 196 個變數，三種變數選擇之預測結果。 . . . . . 17
2 加入月份變數，三種變數選擇之預測結果。 . . . . . 20
3 加入星期變數，三種變數選擇之預測結果。 . . . . . 20
4 加入星期與月份變數，三種變數選擇之預測結果。 . . . . . 21
5 透過三種變數選擇方法，求出之最好的預測模型。 . . . . . 21
6 比較真實選取變數模型與模擬選取變數模型之係數。 . . . . . 25
7 比較真實未選取模型與模擬未選取模型之係數。 . . . . . 28

# 1 緒論

由於日益嚴重的空氣汙染問題，懸浮微粒 (particulate matters i.e. 包括 $PM_{2.5}$, $PM_{10}$) 已成為空氣污染的重要指標。而台灣從 1996 年起，開始在全國的監測站中加裝了 $PM_{2.5}$ 的監控系統，希望借此了解台灣 $PM_{2.5}$ 的汙染情形，自 2011 年 12 月起，環保署提出了「空氣品質標準修正草案」，其中一個目的便是將 $PM_{2.5}$ 加入「空氣汙染防制法規」中，可見懸浮微粒對人體健康的危害，開始受到人們的重視。

在 Pope III(2002) 研究中便指出，細懸浮微粒 ($PM_{2.5}$) 與二氧化硫的相關污染物對於一般死亡率、肺癌以及心肺死亡率皆有顯著的影響，只要細懸浮微粒在空氣中的濃度增加 10 $\mu g/m^3$，則一般的死亡率便會上升 4%、心肺疾病死亡率上升 6% 以及肺癌死亡率上升 8% 。台灣現今每年的吸菸人口逐漸下降，但肺腺癌的發生率卻逐年上升，這個例子便是一個相當明顯的警訊 (見圖 1)。

國立中興大學
National Chung Hsing University

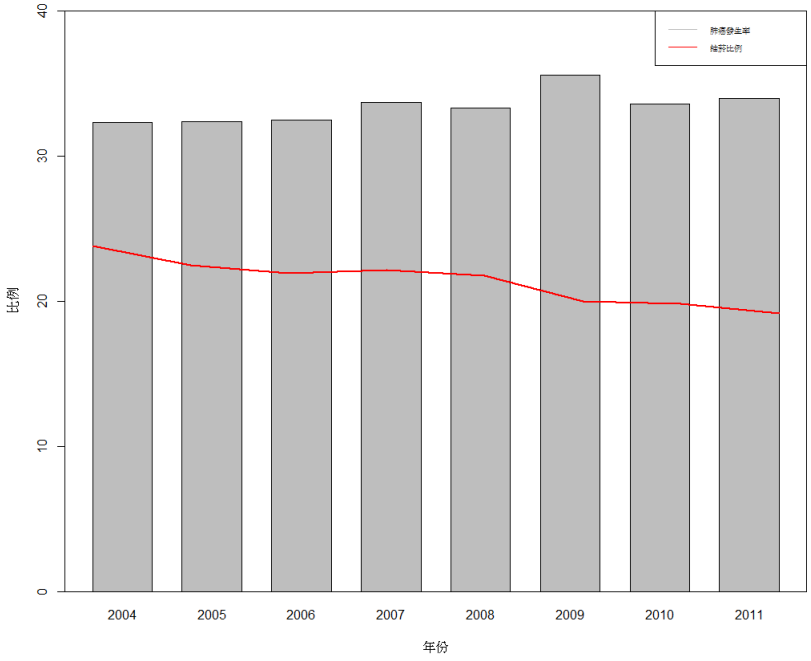



圖 1: 抽菸比例與肺癌發生率對照圖 (資料來源：衛生福利部)。

因此本篇論文主要希望透過蒐集各種與 $PM_{2.5}$ 直接相關或是間接相關的變數，採用三種變數選擇標準：1. 正交貪婪演算法、2.Akaike 訊息判據 (Akaike information criterion; AIC)、3. 貝氏訊息判據 (Bayesian information criterion; BIC)，透過最小平方法 (ordinary least squares, OLS) 來建立迴歸模型，並使用逐步更新預測法 (recursive updating forecasts) 計算每種變數組合之均方誤差，以找出最佳預測模型。

本論文之編排如下：第二章回顧三種變數選擇標準的方法，並介紹有母數拔靴法 (parametric bootstrap method)。第三章詳細敘述從資料蒐集、變數選擇到預測模型建立的過程，第四章則是透過有母數拔靴法模擬原始資料，並將上述提到的三種變數選擇標準重複實驗並加以比較，最後一章則是本論文之結論。

國立中興大學
National Chung Hsing University

# 2 文獻回顧

為了建立 $PM_{2.5}$ 的預測模型，首先需要蒐集各種與 $PM_{2.5}$ 直接相關或是間接相關的變數，在過去有不少的研究對該蒐集哪些的變數加以討論，如在 Voukantsis & Karatzas (2011) 中便使用了兩大類的變數：空氣品質 (Air quality) 跟氣象變數 (Meteorological)。接著在蒐集完變數之後，若將所有的變數全部放入模型中並不符合效益，因此需要使用變數選擇方法進一步將眾多的變數篩選，在參考相關的文獻後，使用了三種方法：AIC、BIC、OGA。透過三種變數選擇方法，以精簡模型並找出有效的預測組合，本論文將在此章節對上述提到的相關文獻一一回顧。

## 2.1 預測模型

在 Voukantsis & Karatzas (2011) 這篇文章中使用了兩大類的變數：空氣品質跟氣象變數。空氣品質這一大類包含了以下這些變數：$NO, NO_2, NO_x, O_3, SO_2, CO, PM_{10}, PM_{2.5}, CP$，其中 CP 與 NO 的定義分別為 $CP = PM_{10} - PM_{2.5}$, $NO = NO_x - NO_2$。而氣象變數則包含了以下這些變數：溫度 (temperature)、相對溼度 (relative humidity)、風速 (wind speed)、風向 (wind direction) ，其中風向變數有經過轉換，定義為：$sinx = sin(2\pi(x - min(x))/(max(x) - min(x)))$，$cosx = cos(2\pi(x - min(x))/(max(x) - min(x)))$，上述式子中的 x 為時間變數，而 sinx 與 cosx 為對應的轉換，並不直接等於 sin(x) 與 cos(x)，作者在上述使用的變數中，透過 PCA 與 ANN-CLP 兩種方法進行變數選擇，如 PCA 主要 $NO_2, CP, PM_{2.5}, O_3, WS, SO_2$ 來建立預測模型，進而比較兩種變數選擇方法之優缺，由於此部分本篇論文未使用，故不多加以介紹。除了該篇文獻使用之變數以外，考慮由於 $PM_{2.5}$ 來源分為原生性的 $PM_{2.5}$ 與衍生性的 $PM_{2.5}$，以及相鄰地域之間的相互影響，境外來源... 等等各種其他因素，因此除了上述使用到的變數之外，將會在第三章詳細介紹其他使用變數。

在蒐集完各個變數之後，接著需要將時間延遲效應列入考慮，對變數進行處理，而經過時間延遲效應轉換後的變數個數將會大幅上升，若仍將所有的變數放

入模型中，一方面會使得預測模型過於龐大，另一方面則會因為加入了某些事前未知，但會增加預測誤差的變數，進而導致預測精準度下降，因此接著必須使用變數選擇方法，將眾多的變數去蕪存菁，進行有效的篩選。在 Hurvich & Tsai (1989) 及 Ing & Lai (2011) 兩篇文章中使用了三種變數選擇方法，分別為：AIC、BIC 與 OGA。

## 2.2 Akaike 訊息判據 (Akaike information criterion; AIC)

這裡定義的符號為 Linhart & Zucchini (1986) 的表示方法，假設資料由真實模型生成。

$$y = \mu + \epsilon \tag{1}$$

其中

$$y = (y_1, y_2, ...y_n)^T \text{，} \mu = (\mu_1, \mu_2, ..., \mu_n)^T \text{，} \epsilon = (\epsilon_1, \epsilon_2, ..., \epsilon_n)^T \text{，}$$

並且 $\epsilon_i$ 為彼此獨立且分配相同之常態分配，其期望值為零，變異數為 $\sigma_0^2$。對於此模型還有額外的假設，考慮一個近似的模型族 (family of models)

$$y = h(\theta) + u \tag{2}$$

其中 $\theta$ 為一個 $m \times 1$ 的向量，

$$u = (u_1, u_2, ..., u_n)^T \text{ ，} h(\theta) = (h_1(\theta), h_2(\theta), ..., h_n(\theta))^T \text{，}$$

假設 $h(\theta)$ 為二階可微，$u_i$ 為彼此獨立且分配相同之常態分配，其期望值為零，變異數為 $\sigma^2$。而 (1) 與 (2) 這兩個模型皆為線性模型 (linear model)，可表示成 $\mu = X_0\theta_0$，$h(\theta) = X\theta$ 其中 $X$ 與 $X_0$ 為 $n \times m_0$ 和 $n \times m$ 之滿秩矩陣，$\theta_0$ 為 $m \times 1$ 之參數向量，接著利用 Kullback-Leibler information 可以測量出兩個模型之差異。

$$\Delta(\theta,\sigma^2) = E_F \{\text{-2log } g_{\theta,\sigma^2}(y)\} \text{，}$$

其中 F 代表第一個模型，$g_{\theta,\sigma^2}(y)$ 代表第二個模型的概似函數 (likelihood function)。接著得到

$$\begin{aligned}\Delta(\theta,\sigma^2) &= -2E_F\log\{(2\pi\sigma^2)^{-1/2n}\exp[-\{y-h(\theta)^T\}\{y-h(\theta)\}/(2\sigma^2)]\ \}\\ &= \text{n log}(2\pi\sigma^2)+E_F\{\mu+\epsilon-h(\theta)\}^T\{\mu+\epsilon-h(\theta)\}\ /\ \sigma^2\\ &= \text{n log}(2\pi\sigma^2)+n\sigma_0^2/\sigma^2+\{\mu-h(\theta)\}^T\{\mu-h(\theta)\}\ /\ \sigma^2\end{aligned}$$

使用 $E_F\{\Delta(\hat{\theta},\hat{\sigma^2})\}$ 當作其判斷的標準，其中 $\hat{\theta},\hat{\sigma^2}$ 為 $\theta,\sigma^2$ 之最大概似估計值 (MLE)，忽略掉常數 nlog$(2\pi)$ 的部分後得到，

$$\Delta(\hat{\theta},\hat{\sigma^2}) = nlog(\hat{\sigma^2}) + n\sigma_0^2/\hat{\sigma^2}+\{\mu-h(\hat{\theta})\}^T\{\mu-h(\hat{\theta})\}\ /\ \hat{\sigma}^2$$

雖然 $E_F\{\Delta(\hat{\theta},\hat{\sigma^2})\}$ 未知，但在特定的假設成立時它是可以估計的。

$$AIC = n(log\sigma^2+1)+2(m+1) \tag{3}$$

而 AIC( Akaike information criterion) 就是用來算出 $E_F\{\Delta(\hat{\theta},\hat{\sigma^2})\}$ 近似的不偏估計，其中 m 為其近似模型之維度。

國立中興大學 National Chung Hsing University

## 2.3 貝氏訊息判據 (Bayesian information criterion; BIC)

在此定義的符號為 Neath & Cavanaugh (2012) 之表示方法，y 為從一個候選模型群 $M_{k_1},M_{k_2},...,M_{k_L}$ 裡選出的模型 $M_k$ 所描述之觀測資料，並假設每一個 $M_k$ 都有唯一向量參數 $\theta_k$，其中 $\theta_k$ 為參數空間 $\Theta(k)$ 中之元素，$k\in\{k_1,k_2,...,k_L\}$。基於 $M_k$ 下，$L(\theta_k|y)$ 為 y 之概似函數，$\hat{\theta_k}$ 為 $\theta_k$ 之最大概似估計值 (MLE)，$\pi(k)$ 為 $M_{k_1},M_{k_2},...,M_{k_L}$ 模型之離散先驗分配 (discrete prior)，給定模型 $M_k$ 下 $g(\theta_k|k)$ 為 $\theta_k$ 之先驗分配 (prior)。

$$h((k,\theta_k)|y) = \frac{\pi(k)g(\theta_k)L(\theta_k|y)}{m(y)} \tag{4}$$

其中 $m(y)$ 為 y 之邊際分配 (marginal distribution)。

$$P(k|y) = m(y)^{-1}\pi(k)\int L(\theta_k|y)g(\theta_k|k)d\theta_k \tag{5}$$

現在最小化 $-2lnP(k|y)$，

$$-2lnP(k|y) = 2ln\{m(y)\}-2ln\{\pi(k)\}-2ln\{\textstyle\int L(\theta_k|y)g(\theta_k|y)d\theta_k\}$$

$$
\begin{aligned}
-2lnP(k|y) &\propto -2ln\{\pi(k)\} \\
&\quad -2ln\{\int L(\theta_k|y)g(\theta_k|y)d\theta_k\} \\
&\quad \equiv S(k|y)
\end{aligned}
$$

由泰勒展式

$$
\begin{aligned}
lnL(\theta_k|y) &\approx lnL(\hat{\theta_k}|y) + (\theta_k - \hat{\theta_k})' \frac{\partial ln(\hat{\theta_k}|y)}{\partial \theta_k} + \frac{1}{2}(\theta_k - \hat{\theta_k})' [\frac{\partial^2 ln(\hat{\theta_k}|y)}{\partial \theta_k \partial \theta_k'}] \\
&= ln(\hat{\theta_k}|y) - \frac{1}{2}(\theta_k - \hat{\theta_k})' [n\overline{\mathcal{I}}(\hat{\theta_k}|y)](\theta_k - \hat{\theta_k}),\ \overline{\mathcal{I}}(\hat{\theta_k}|y) = -\frac{1}{n}\frac{\partial^2 ln(\hat{\theta_k}|y)}{\partial \theta_k \partial \theta_k'}
\end{aligned}
$$

由於

$$
L(\theta_k|y) \approx L(\hat{\theta_k}|y) exp\{-\frac{1}{2}(\theta_k - \hat{\theta_k})' [n\overline{\mathcal{I}}(\hat{\theta_k}|y)](\theta_k - \hat{\theta_k})\}
$$

所以第 (5) 式積分就可以近似為

國立中興大學
National Chung Hsing University

$$
\int L(\theta_k|y)g(\theta_k|y)d\theta_k \approx L(\hat{\theta_k}|y) \int exp\{-\frac{1}{2}(\theta_k - \hat{\theta_k})' [n\overline{\mathcal{I}}(\hat{\theta_k}|y)](\theta_k - \hat{\theta_k})\} g(\theta_k|k) d\theta_k
$$

若令其中無訊息先驗分配 (noninformative prior)，$g(\theta_k|k) = 1$，則原式變為

$$
\begin{aligned}
&\int exp\{-\frac{1}{2}(\theta_k - \hat{\theta_k})' [n\overline{\mathcal{I}}(\hat{\theta_k}|y)](\theta_k - \hat{\theta_k})\} g(\theta_k|k) d\theta_k \\
&= \int exp\{-\frac{1}{2}(\theta_k - \hat{\theta_k})' [n\overline{\mathcal{I}}(\hat{\theta_k}|y)](\theta_k - \hat{\theta_k})\} d\theta_k \\
&= (2\pi)^{k/2} |n\overline{\mathcal{I}}(\hat{\theta_k, y})^{-1/2}|
\end{aligned}
$$

所以

$$\begin{aligned}
&\int L(\theta_k|y)g(\theta_k|y)d\theta_k \\
&\approx L(\theta_k|y)(2\pi)^{k/2}|n\overline{\mathcal{I}}(\hat{\theta_k}, y)^{-1/2}| \\
&= L(\theta_k|y)(2\pi)^{k/2}n^{-k/2}|\overline{\mathcal{I}}(\hat{\theta_k}, y)^{-1/2}| \\
&= L(\theta_k|y)(\frac{2\pi}{n})^{k/2}|\overline{\mathcal{I}}(\hat{\theta_k}, y)^{-1/2}|
\end{aligned}$$

接著可以得到

$$\begin{aligned}
S(k|y) &= -2ln\{\pi(k)\} - 2ln\{\int L(\theta_k|y)g(\theta_k|y)d\theta_k\} \\
&\approx -2ln\{\pi(k)\} - 2ln[L(\hat{\theta_k}|y)(\frac{2\pi}{n})^{k/2}|\overline{\mathcal{I}}(\hat{\theta_k}, y)^{-1/2}|] \\
&= -2ln\{\pi(k)\} - 2lnL(\hat{\theta_k}|y) + k\{ln(\frac{n}{2\pi})\} + ln|\overline{\mathcal{I}}(\hat{\theta_k}, y)^{-1/2}| \\
&\approx -2lnL(\hat{\theta_k}|y) + k\ ln\ n
\end{aligned}$$

國立中興大學
National Chung Hsing University

所以 Bayesian(Schwarz) information criterion (BIC) 即可定義如下：

$$BIC = -2lnL(\hat{\theta_k}|y) + k\ ln\ n \tag{6}$$

$$= -2lnf(y|\hat{\theta_k}) + k\ ln\ n \tag{7}$$

## 2.4 正交貪婪法 (orthogonal greedy algorithm; OGA)

這個方法主要是針對高維度的迴歸模型，考慮如何去選擇變數。通常如果想解決這種變數個數較多，甚至是變數個數比樣本數還要大的問題時，常會假設這些迴歸係數需要滿足稀疏性 (sparsity condition)。稀疏性分為兩種：一是強稀疏性 (strong sparsity)，意即假設非零的係數的個數比樣本數 (n) 小很多；另一種則是弱稀疏性 (weak sparsity)，意即假設大部分的係數都很小，只有少部分的係數較為顯著。而在銀慶剛 (2015) 以及 Ing & Lai (2011) 的論文中則使用了正交貪婪演算法來處理高維度迴歸模型的問題。他們設計了一個高維的訊息準則 (High-Dimensional Information Criterion, HDIC)，並證明在在弱稀疏性的情況下，

使用 OGA 加上 HDIC 具有最佳的預測結果。以下是這個 OGA 方法的主要步驟：

- Step.1

  定義:$\hat{R}_0 = Y = (y_1, y_2, ..., y_n)^T$，並找出 $X_{\hat{s}_1}$，使得

  $$cor(\hat{R}_0, X_{\hat{s}_1}) \geq cor(\hat{R}_0, X_{\hat{s}_i}), \quad i = 2, ..., p$$

- Step.2

  透過最小平方法 (ordinary least squares, OLS)，將 $X_{\hat{s}_1}$ 對 $\hat{R}_0$ 作迴歸得到 $\hat{\beta}^1_{\hat{s}_1}$ 與 $\hat{R}_1$

  $$\hat{R}_1 = \hat{R}_0 - \hat{\beta}^1_{\hat{s}_1} X_{\hat{s}_1}$$

- Step.3

  得到 $\hat{R}_1$ 後，回到 Step.1，在所有的變數當中找出 $X_{\hat{s}_2}$ 與 $\hat{R}_2$；

  $$\hat{R}_2 = \hat{R}_0 - \hat{\beta}^2_{\hat{s}_1} X_{\hat{s}_1} - \hat{\beta}^2_{\hat{s}_2} X_{\hat{s}_2}$$

  以此類推，可以重複 m 次找出 $X_{\hat{s}_i}$ 與對應 $X_{\hat{s}_i}$ 的係數 $\hat{\beta}^m_{\hat{s}_i}$ (其中 $i = 1, 2, ..., m$)。

AIC, BIC, OGA 此三種變數選擇方法，我們將在 3.2.2 挑選變數中使用，並運用此結果計算出各個均方誤差 (mean squared error; MSE)，比較其預測準度。

## 2.5 有母數拔靴法 (parametric bootstrap method)

由於三種變數選擇方法之變數選擇結果並不相同，若只使用某一地點之真實資料加以進行比較，無法保證該結論之可信度，因此為了驗證上述三種變數選擇方法之預測效果，本篇論文中使用了有母數拔靴法 (Parametric Bootstrap method) 生成模擬資料，來近似本文中所有蒐集之變數，每生成一次資料便進行一次變數選擇，並記錄每次實驗之結果。在五百次的實驗之後，分析此五百次實驗記錄，比較在不同需求下三種變數選擇方法之優劣，藉以提高此變數選擇時驗之參考價值與可信度。在此參考 Kreiss & Lahiri (2012) 的說明。

- 單變量 AR(p) 模型

  首先假設一組觀測值 $X$ 服從 AR(p)，以及有母數估計值 $\hat{\varphi}_1,\ \hat{\phi}_1, ..., \hat{\phi}_p$，p 為一固定常數，則可得到

$$X_{t+1} = \hat{\varphi}_1 + \hat{\phi}_1 X_t + \hat{\phi}_2 X_{t-1} + ... + \hat{\phi}_p X_{t-p+1} + \hat{e_{t+1}} \tag{8}$$

$$\hat{e_t} = X_{t+1} - \hat{\varphi}_1 - \hat{\phi}_1 X_t - ... - \hat{\phi}_p X_{t-p+1},\ t = p, ..., n-1 \tag{9}$$

  有母數拔靴法是由 (9) 所得到之殘差 $(\hat{e_{t+1}}, ..., \hat{e_n})$ 中，進行抽後放回之重複抽樣，以得到一組 $e_1^*, ..., e_n^*$，並利用此殘差與其自身之有母數估計值，代入 (8) 計算出每一筆模擬資料，

$$X_{t+1}^* = \hat{\varphi}_1 + \hat{\phi}_1 X_t^* + \hat{\phi}_2 X_{t-1}^* + ... + \hat{\phi}_p X_{t-p+1}^* + e_{t+1}^* \quad t = 0, ..., n-1$$

- 多變量時間序列迴歸模型

  而在多變量時間序列時，假設 $X_1, X_2, ..., X_k$ 服從 $AR(p_1), ..., AR(p_k)$，$p_1, ..., p_k$ 為一固定常數，

$$\begin{aligned}
X_{1(t+1)} &= \hat{\varphi_{11}} + \hat{\phi_{11}} X_{1t} + \hat{\phi_{12}} X_{1(t-1)} + ... + \hat{\phi_{1p1}} X_{1(t-p_1+1)} + e_{1(t+1)} \\
X_{2(t+1)} &= \hat{\varphi_{21}} + \hat{\phi_{21}} X_{2t} + \hat{\phi_{22}} X_{2(t-1)} + ... + \hat{\phi_{2p2}} X_{2(t-p_2+1)} + e_{2(t+1)} \\
&\vdots \\
X_{k(t+1)} &= \hat{\varphi_k} + \hat{\phi_{k1}} X_{kt} + \hat{\phi_{k2}} X_{k(t-1)} + ... + \hat{\phi_{kpk}} X_{k(t-p_k+1)} + e_{k(t+1)}
\end{aligned}$$

  假設 $Y$ 由 $X_1 Lagl_1, X_2 Lagl_2, ..., X_k Lagl_k$ 構成迴歸模型：

$$\begin{aligned}
Y_{t+1} = \hat{\beta}_0 + \hat{\beta_{11}} X_{1t} + ... + \hat{\beta_{1(l_1)}} X_{1(t-l_1+1)} + \\
\hat{\beta_{21}} X_{2t} + ... + \hat{\beta_{2(l_2)}} X_{2(t-l_2+1)} + \\
\vdots \\
\hat{\beta_{k1}} X_{kt} + ... + \hat{\beta_{k(l_k)}} X_{k(t-l_k+1)} + \epsilon_{Y_{t+1}}
\end{aligned}$$

  並由上述式子之殘差，合成殘差矩陣 E：

$$E = \begin{pmatrix}
\epsilon_{Y_1} & e_{11} & \cdots & e_{k1} \\
\epsilon_{Y_2} & e_{12} & \cdots & e_{k2} \\
\vdots & \vdots & \ddots & \vdots \\
\epsilon_{Y_n} & e_{1n} & \cdots & e_{kn}
\end{pmatrix}$$

國立中興大學 National Chung Hsing University

接著便可使用有母數拔靴法，對殘差矩陣 E 進行抽後放回之重複抽樣，在此要注意的是，由於各個變數之間有時間前後之交互影響性質，因此在抽取殘差時一次是隨機抽出其中一列，此方法可以保留變數間之相互影響性質，接著便利用抽出的殘差與自身之有母數估計值，代入自身對應的式子，計算出每一筆模擬資料。

$$X^*_{1(t+1)} = \hat{\varphi_1} + \hat{\phi_1} X^*_{1t} + \hat{\phi_2} X^*_{1(t-1)} + ... + \hat{\phi_{p_1}} X^*_{1(t-p_1+1)} + e^*_{1(t+1)} \tag{10}$$

$$\begin{aligned} Y^*_{t+1} = \hat{\beta}_0 + \hat{\beta_{11}} Y^*_{1t} + ... + \hat{\beta_{1p_1}} Y^*_{1(t-l_1+1)} + \\ \hat{\beta_{21}} X^*_{2t} + ... + \hat{\beta_{2p_2}} X^*_{2(t-l_2+1)} + \\ \vdots \\ \hat{\beta_{k1}} X^*_{kt} + ... + \hat{\beta_{kp_k}} X^*_{k(t-l_k+1)} + \epsilon^*_{Y_{t+1}} \end{aligned} \tag{11}$$

以本論文的資料結構為例：

假設 n 為變數個數，i 為變數 x 之個數，$p_i$ 為落後期數，$x_i \sim AR(p_i)$，

$$X_{i(t+1)} = \hat{\varphi_i} + \hat{\phi_1} X_{it} + \hat{\phi_2} X_{i(t-1)} + ... + \hat{\phi_{p_1}} X_{i(t-p_i+1)} + e_{i(t+1)} \tag{12}$$

國立中興大學
National Chung Hsing University

並且本篇論文在第四章假設 $PM_{2.5}$ 之真實模型為

$$\begin{aligned} Y_{t+1} = \hat{\beta}_0 + \hat{\beta}_1 Y_{t-1} + \hat{\beta}_2 X_{1(t-1)} + \hat{\beta}_3 X_{2(t-1)} + \hat{\beta}_4 X_{3(t-1)} + \hat{\beta}_5 X_{4(t-1)} \\ + \hat{\beta}_6 X_{4(t-2)} + \hat{\beta}_7 X_{5(t-2)} + \epsilon_{Y_{t+1}} \end{aligned} \tag{13}$$

透過 (12) 與 (13) 可求出其對應之殘差矩陣 E：

$$E = \begin{pmatrix} \epsilon_{Y_1} & e_{11} & \cdots & e_{51} \\ \epsilon_{Y_2} & e_{12} & \cdots & e_{52} \\ \vdots & \vdots & \ddots & \vdots \\ \epsilon_{Y_n} & e_{1n} & \cdots & e_{5n} \end{pmatrix}$$

接著對殘差矩陣 E 進行抽後放回之隨機抽樣，即每次從殘差矩陣 E 中隨機抽出一列殘差，代入 (10) 與 (11) 以生成資料。在此還有另外一個重點是，由於生成時並沒有所有 X 變數的初始值，因此 X 變數之初始值以其抽出之對應殘差項取代，而 Y 變數之部分由於是透過 X 變數進行生成，故在

$x_{i(t-pi)}$ 有值以前，皆設定其值為 0。以 (12) 與 (13) 為例：假設第一次從殘差矩陣 E 中抽出的殘差為 $(\epsilon_{Yi}, e_{1i}, e_{2i}, e_{3i}, e_{4i}, e_{5i})$，則 $X_1, ..., X_5, Y$ 分別為

$$X_{11}^* = e_{1i}\ , X_{21}^* = e_{2i}\ , X_{31}^* = e_{3i}\ , X_{41}^* = e_{4i}\ , X_{51}^* = e_{5i}$$
$$Y_1^* = 0$$

接著假設第二次從殘差矩陣 E 中抽出的殘差為 $(\epsilon_{Y_{i+1}}, e_{1(i+1)}, e_{2(i+1)}, e_{3(i+1)}, e_{4(i+1)}, e_{5(i+1)})$，則 $X_1, ..., X_5, Y$ 分別為

$$X_{12}^* = \hat{\varphi}_1 + \hat{\phi_{11}} X_{11}^* + e_{1(i+1)},\quad X_{22}^* = \hat{\varphi}_2 + \hat{\phi_{21}} X_{21}^* + e_{2(i+1)}\ ,$$
$$X_{32}^* = \hat{\varphi}_3 + \hat{\phi_{31}} X_{31}^* + e_{3(i+1)},\quad X_{42}^* = \hat{\varphi}_4 + \hat{\phi_{41}} X_{41}^* + e_{4(i+1)}\ ,$$
$$X_{52}^* = \hat{\varphi}_5 + \hat{\phi_{51}} X_{51}^* + e_{5(i+1)}\ ,$$
$$Y_2^* = 0$$

此時由於每個 X 變數皆只有兩筆資料，以及 Y 的第一筆資料為 0，因此 $Y^*$ 需要等到第三筆資料開始生成，才會出現第一個值。在生成出需要的資料筆數之後，最後需要將前面初始部分的資料刪除，以減少初始假設其值為誤差項以及 0 之影響，如第四章模擬總共生成 1500 筆資料，則將前兩百筆資料刪除，使用後 1300 筆資料來進行統計分析。本文將在第四章使用此方法模擬真實資料，並使用三種變數選擇方法進行模擬實驗，加以重複比較並分析結果。

國立中興大學 National Chung Hsing University

# 3 預測模型建立

## 3.1 資料結構

本論文選擇大里之 $PM_{2.5}$ 作為預測目標。從 2011/01/01~2014/12/31，蒐集了四年共 1461 筆的資料，前三年作為訓練資料，後一年作為測試資料。

## 3.2 變數選擇

### 3.2.1 使用變數

- (1) 空氣品質變數:
  $NO, NO_2, NO_x, O_3, SO_2, CO, PM10, PM2.5, NMHC, THC$

  由於 $PM_{2.5}$ 分成兩類，一種為原生性的 $PM_{2.5}$，意指由人為活動產生或是經由大自然釋出的 $PM_{2.5}$，而另一種則是當空氣中原生性的 $PM_{2.5}$ 受到其他因素的影響後，產生化學反應並形成新的化學物質，例如像是二氧化硫會衍生成為硫酸鹽。此種類型的 $PM_{2.5}$ 稱為衍生性的 $PM_{2.5}$，這些化學物質包含：硫酸鹽、硝酸鹽、銨鹽。最後是由交通工具與工廠所排放出的碳氫化合物 (HC)，即包含總碳氫化合物 (THC)、非甲烷碳氫化合物 (NMHC) 與二氧化碳 (CO2)，將這些變數列入考慮，測試其預測效果。

- (2) 氣象變數:
  溫度、相對濕度、風向、風速、降雨量

  一般的顆粒較大的懸浮微粒，如 $PM_{10}$ 會因地心引力在幾個小時之內而落地，但是顆粒較小的 $PM_{2.5}$ 因為會隨著風長時間在空氣中懸浮，直到下雨時才會附著在雨水上落地。Tai et al. (2010) 利用多元線性迴歸方法分析 $PM_{2.5}$ 與大氣條件的關係，發現由溫度、降雨、相對溼度、環流組合在一起的迴歸公式可以解釋超過 50% 的 $PM_{2.5}$ 濃度，並且其中很明顯與 $PM_{2.5}$ 呈現負相關的變數即是降雨，因為降雨使得漂浮在大氣中細懸浮微粒濃度降低，所以在此加入降雨量作為預測變數之一。

國立中興大學 National Chung Hsing University

- (3) 周圍測站:

  忠明、西屯、豐原、沙鹿、南投、埔里、竹山、彰化、二林、線西。

  (即所有之中部測站) 境外來源指標測站: 金門、馬祖。

由上述提到的 $PM_{2.5}$ 因為長時間在大氣中懸浮，導致目標測站周圍區域之空氣汙染物在一段時間之後，受到風速及風向的影響會飄至所設定的預測區域；而中國大陸的沙塵暴中也含有各種的懸浮微粒，原生性與衍生性兩種均可能存在，大氣中的氣流可以將這些微粒移動到較遠的地區，例如韓國、日本與台灣，所以在春、冬兩季東北季風強盛時，容易出現 $PM_{2.5}$ 濃度上升的情形，此即是境外移入來源。根據環保署的統計資料，境外移入來源佔了台灣 $PM_{2.5}$ 濃度 37%，所以除了將預測目標地區之周圍中部測站列入之外，也將金門、馬祖兩個監測站作為境外移入部分之前哨站，作為預測變數。

國立中興大學
National Chung Hsing University

- (4) 月份與季節變數：

  首先先觀察目標預測站: 大里，四年的 $PM_{2.5}$ 趨勢圖。

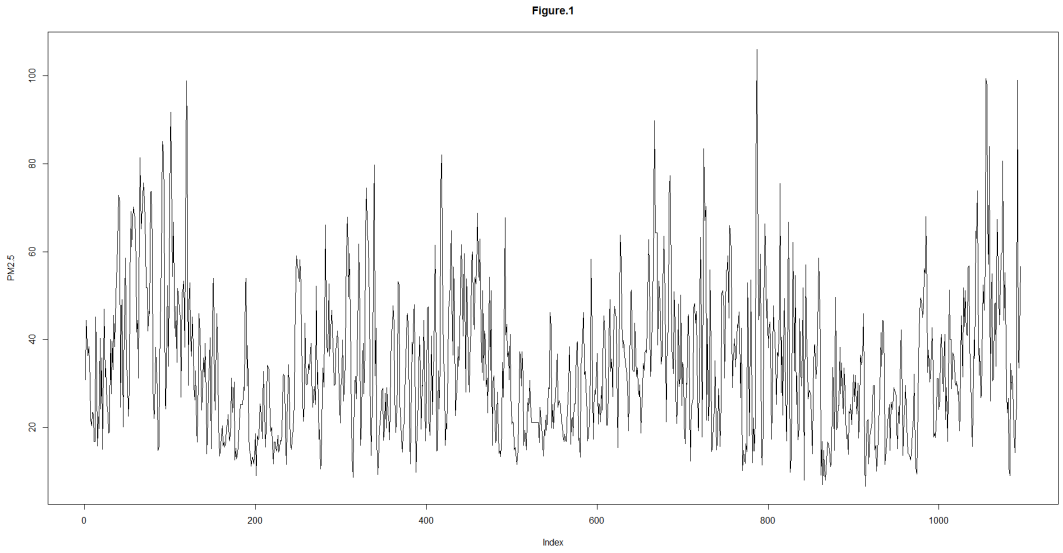



圖 2: 大里 2011 到 2014 之 $PM_{2.5}$ 趨勢圖。

由圖 2 可以清楚地發現由於春冬兩季東北季風強盛，這兩個季節的 $PM_{2.5}$ 偏高，而夏秋兩季則偏低，每年皆有這樣的趨勢，所以在預測模型的變數中，將比較添加月份變數前後，其預測誤差的變化。

- (5) 時間延遲效應：
  最後由於未來的 $PM_{2.5}$ 乃過去各種相關變數之影響，因此上述 28 種變數，再分別往前平移落後一期到落後七期，亦即共有 $28 \times 7 = 196$ 個變數。

### 3.2.2 挑選變數

在此挑選變數使用三種方法來挑選

- (1) 逐步迴歸法以 AIC(3) 為選擇標準，意指如果加入了 a 這個變數之後模型的 AIC 上升，則刪除 a 變數；反之，若加入之後 AIC 下降則該變數留下。選擇方向為雙向，意指任何的解釋變數被加入該模型之後，仍然有可能在稍後被刪除，或者被刪除之後再度被加回來。

國立中興大學
National Chung Hsing University

- (2) 逐步迴歸法，以 BIC(7) 為選擇標準，選取規則說明同上，只是選擇標準從 AIC 改為 BIC。

- (3) 貪婪正交法 (orthogonal greedy algorithm, OGA)
  首先定義 $\hat{R}_0 = Y =$ 目標地之 $PM_{2.5}$，並在 196 個變數中找出與 $\hat{R}_0$ 相關性最高的變數 $X_{\hat{s_1}}$，則 $X_{\hat{s_1}}$ 為第一組候選人，接著將 $X_{\hat{s_1}}$ 對 $\hat{R}_0$ 做迴歸得到 $\hat{R}_1 = \hat{R}_0 - \hat{\beta}^1_{\hat{s_1}} X_{\hat{s_1}}$，再從剩下的 195 個變數中找出與 $\hat{R}_1$ 相關性最高的變數 $X_{\hat{s_2}}$，則 $\{X_{\hat{s_1}}, X_{\hat{s_2}}\}$ 為第二組候選人。以此類推，總共可以得到 196 組候選人。

## 3.3 預測結果判斷標準

由於本論文使用時間序列的資料，因此本文中使用逐步更新預測法 (recursive updating forecasts) 來計算每個候選組合之均方誤差。使用模型為 (12) 與 (13)：

$$X_{i(t+1)} = \hat{\varphi}_i + \hat{\phi}_1 X_{it} + \hat{\phi}_2 X_{i(t-1)} + ... + \hat{\phi}_{p_1} X_{1(t-p_1+1)} + e_{1(t+1)}$$

$$\begin{aligned} Y_{t+1} = \hat{\beta}_0 + \hat{\beta}_1 Y_{t-1} + \hat{\beta}_2 X_{1(t-1)} + \hat{\beta}_3 X_{2(t-1)} + \hat{\beta}_4 X_{3(t-1)} + \hat{\beta}_5 X_{4(t-1)} \\ + \hat{\beta}_6 X_{4(t-2)} + \hat{\beta}_7 X_{5(t-2)} + \epsilon_{Y_{t+1}} \end{aligned}$$

其中 Y 為目標地之 $PM_{2.5}$。逐步更新預測法流程如下：

- Step1. 首先必須建立模型對應的設計矩陣

$$X = \begin{pmatrix} 1 & X_{12} & X_{22} & \cdots & X_{53} \\ 1 & X_{13} & X_{23} & \cdots & X_{54} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{1(t-1)} & X_{2(t-1)} & \cdots & X_{5(t-2)} \end{pmatrix}$$

- Step2. 接著使用最小平方法來估計模型中每一個變數 X 所對應之參數 $\hat{\beta}$，

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

國立中興大學
National Chung Hsing University

- Step3. 得到參數之後，其預測模型可以表示為：

$$\begin{aligned} Y^*_{t+1} = \hat{\beta}_0 + \hat{\beta}_1 Y_{t-1} + \hat{\beta}_2 X_{1(t-1)} + \hat{\beta}_3 X_{2(t-1)} + \hat{\beta}_4 X_{3(t-1)} + \hat{\beta}_5 X_{4(t-1)} \\ + \hat{\beta}_6 X_{4(t-2)} + \hat{\beta}_7 X_{5(t-2)} + \epsilon_{Y_{t+1}} \end{aligned}$$

- Step4. 預測模型建立完成後，便可以得到大里第 T+1 天 $PM_{2.5}$ 的預測值 $Y^*_{t+1}$，與預測誤差 $\hat{\epsilon}_{t+1} = Y^*_{t+1} - Y_{t+1}$

- Step5. 接著預測第 T+2 天時，設計矩陣中 X 的部分皆往後平移一天，所建立新的設計矩陣為

$$X = \begin{pmatrix} 1 & X_{13} & X_{23} & \cdots & X_{54} \\ 1 & X_{14} & X_{24} & \cdots & X_{55} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{1t} & X_{2t} & \cdots & X_{5(t-1)} \end{pmatrix}$$

這邊要特別注意的是在預測下一天的 $PM_{2.5}$ 時，由於設計矩陣不斷往後平移，當使用到第 t+1 天的資料時，這一天的資料必須使用真實值 $Y_{t+1}$ 來建立，而非前一步所預測出的 $Y^*_{t+1}$，假如使用了 $Y^*_{t+1}$ 則計算出來的預測值會因為包含先前的預測誤差，導至預測結果越來越不準。

- Step6.

  最後不斷重複 Step1∼ Step4 總共可以得到 $Y^*_{t+1}, Y^*_{t+2}, ..., Y^*_{t+365}$ 共 365 個預測資料，以及 $(\hat{\epsilon}_{t+1}, \hat{\epsilon}_{t+2}, ..., \hat{\epsilon}_{t+365})$ 共 365 個預測誤差，利用這 365 個預測誤差可以求出此候選變數組合之均方誤差

$$\begin{aligned} MSE &= \frac{1}{365}\sum_{i=1}^{365}(Y^*_{t+i} - Y_{t+i})^2 \\ &= \frac{1}{365}\sum_{i=1}^{365}(\hat{\epsilon}_{t+i})^2 \end{aligned}$$

- Step7.

  最後選出所有的候選變數組合裡，均方誤差最低的變數組合，即為最佳的預測模型。

國立中興大學
National Chung Hsing University

## 3.4 預測結果

| 方法 | 變數個數 | 均方誤差 |
|---|---|---|
| AIC | 62 | 193.9166 |
| BIC | 14 | 192.0049 |
| OGA | 156 | 180.9714 |

表 1: 使用 196 個變數，三種變數選擇之預測結果。

由表一可以觀察出使用 OGA 做為變數選擇的方法，其預測誤差最小，不過變數選擇個數較多。接著觀查使用 OGA 做為變數選擇方法下，其預測誤差逐遞的變化情形，並在最低均方誤差的位置畫上一條紅線做為基準線。

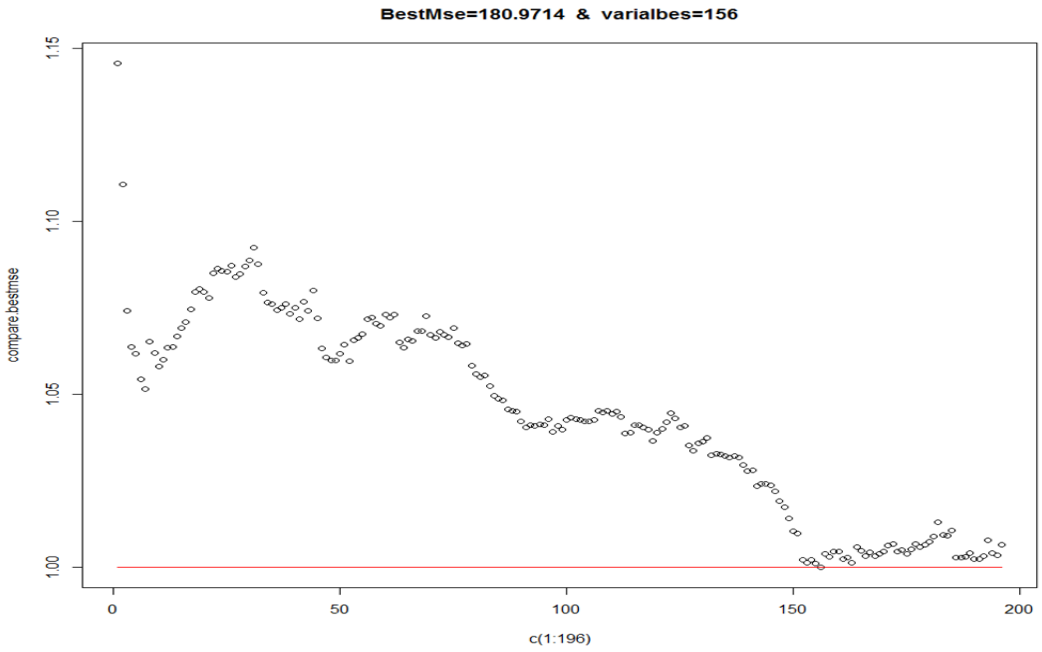



圖 3: 均方誤差隨著變數增加之變化情形。

接著將預測這一年 365 天，每天的真實值、預測值、取完絕對值之預測誤差畫出。

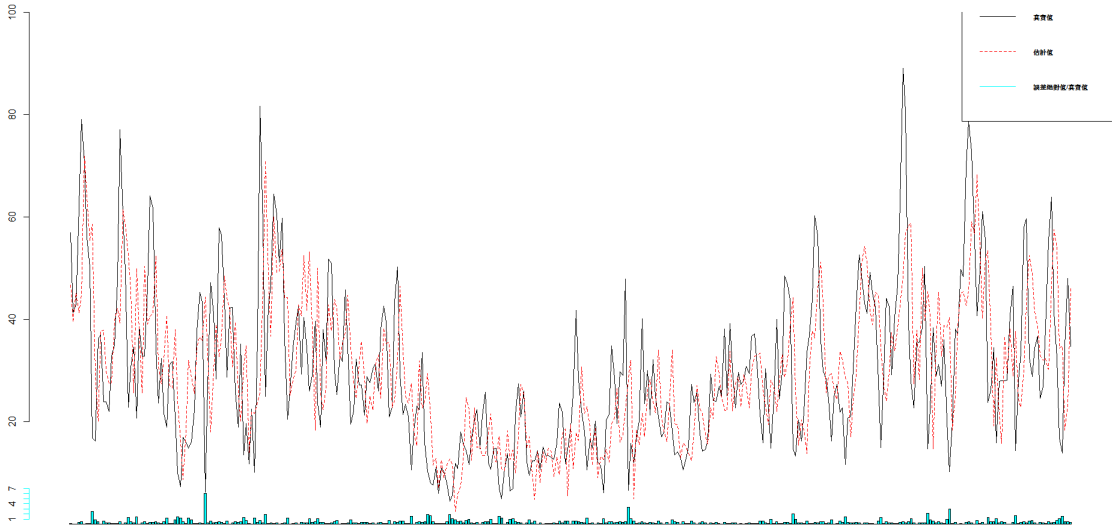


圖 4: 真實值、預測值、取完絕對值之預測誤差

現在將預測誤差除上對應的真實觀測值，此轉換目的在於：當真實觀測值較大時，其預測誤差的值也會較大，容易造成誤判。得到轉換後的預測誤差再將其分類，依次為: 星期、月份、是否降雨分類，以上三類皆為當日之星期、月份、是否降雨，而非前一天，也就是說藉由這三種分類觀察是否因為今天是星期幾？是否因為今天是幾月份？是否因為今天是否降雨？而 $PM_{2.5}$ 預測較為不準？

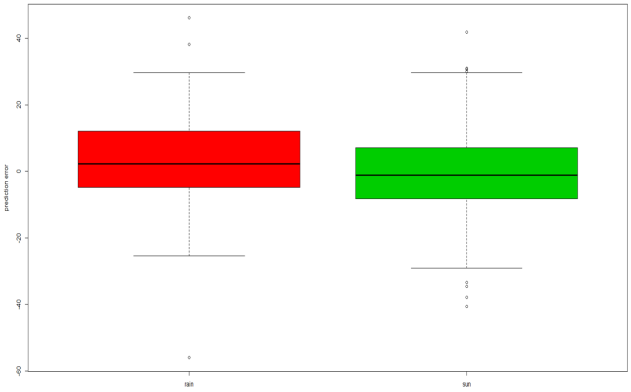


圖 5: 是否降雨之預測誤差

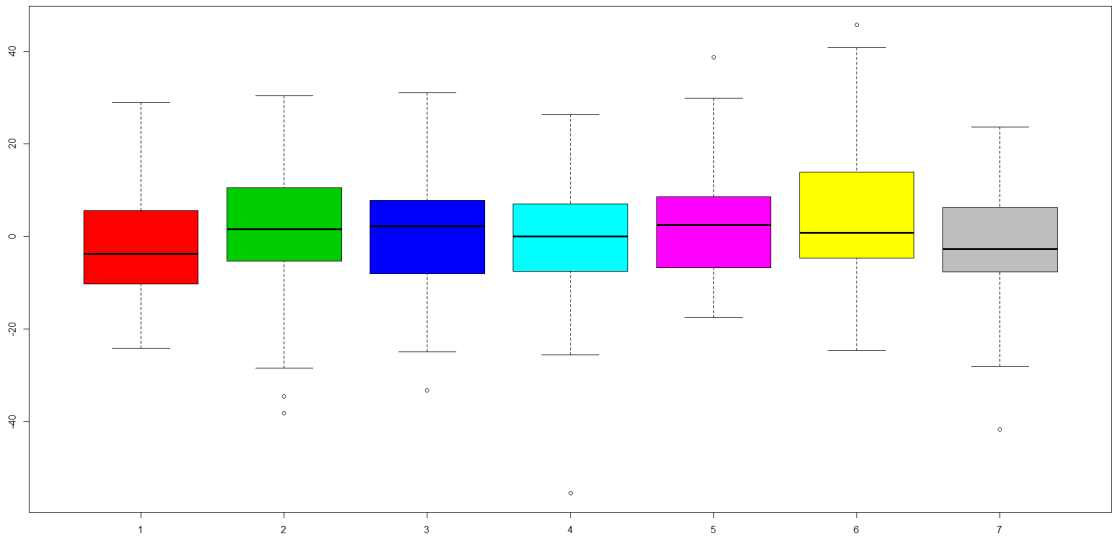



圖 6: 依星期分類後之預測誤差

國立中興大學
National Chung Hsing University

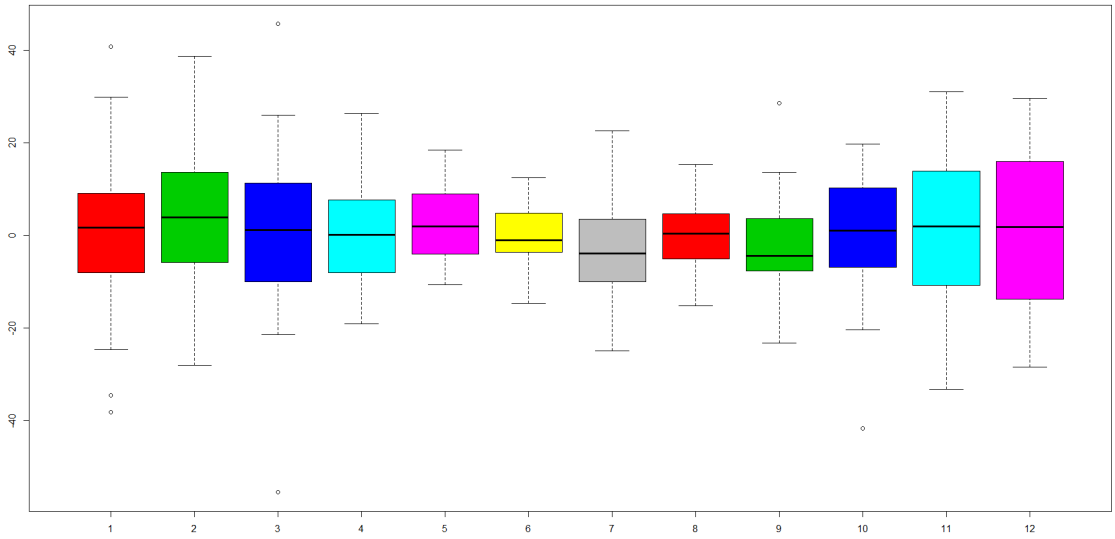



圖 7: 依月份分類後之預測誤差

由圖 5 是否降雨，以及圖 6 由星期一到星期日來分類預測誤差這兩張圖，可以觀察到其資料的分佈差異不大；但是圖 7 由月份來分類的預測誤差可以觀察出一個明顯的趨勢，在冬、春兩個季節預測得比較容易不準，推測是由於 $PM_{2.5}$ 之境外來源，即細懸浮微粒伴隨著東北季風而來進而影響台灣的空氣品質，所以考慮在原有的變數選擇結果下，再加入月份做為預測的變數，來觀察是否會改善先前的預測結果。

| 方法 | 變數個數 | 原均方誤差 | 新均方誤差 |
|---|---|---|---|
| 若加入月份之變數 (month) | | | |
| AIC+month | 73 | 193.9166 | 190.0705 |
| BIC+month | 25 | 192.0049 | 188.098 |
| OGA+month | 167 | 180.9714 | 176.5801 |

表 2: 加入月份變數，三種變數選擇之預測結果。

國立中興大學 National Chung Hsing University

由表 2 可以觀察到，將月份變數加入三個候選模型時，其均方誤差皆有些許的下降，改善了預測的精準度。接著在剛剛提及的圖 7 由星期一到星期日來分類預測誤差的部分，雖然其預測誤差並沒有明顯的不同，但是由於星期依舊會影響大多數民眾與工廠是否上班或是放假，進而影響其 $PM_{2.5}$ 之數值，所以在此嚐試將星期之變數做為預測的變數，放入原本變數選擇結果的三個模型中，來觀察其預測結果是否會比原本的模型來的好？

| 方法 | 變數個數 | 原均方誤差 | 新均方誤差 |
|---|---|---|---|
| 若加入星期之變數 (week) | | | |
| AIC+week | 68 | 193.9166 | 192.3582 |
| BIC+week | 20 | 192.0049 | 190.4383 |
| OGA+week | 162 | 180.9714 | 180.2004 |

表 3: 加入星期變數，三種變數選擇之預測結果。

由表 3 可以觀察到，將星期變數加入三個候選模型時，其均方誤差只有下降一點點，預測的改善並不理想，可見星期雖然會影響民眾與工廠是否上班，但是對於整體 $PM_{2.5}$ 的影響可能並不高。最後嘗試若是將星期與月份之變數同時放入模型中，其預測結果是否會比單純只放入月分之變數來的好？

| 方法 | 變數個數 | 月份均方誤差 | 月份 + 星期均方誤差 |
|---|---|---|---|
| 若同時加入月份與星期之變數 | | | |
| AIC+month+week | 79 | 190.0705 | 188.8752 |
| BIC+month+week | 31 | 188.098 | 186.6425 |
| OGA+month+week | 173 | 176.5801 | 176.017 |

表 4: 加入星期與月份變數，三種變數選擇之預測結果。

雖然同時將星期與月份之變數全部放入時，其均方誤差比只放入月份的均方誤差來的低，但是改善程度並不明顯，因此總結表 1 ∼ 4，可以得到目前最好的預測模型為:

國立中興大學
National Chung Hsing University

| 方法 | 變數個數 | 均方誤差 |
|---|---|---|
| OGA+month | 167 | 176.5801 |

表 5: 透過三種變數選擇方法，求出之最好的預測模型。

接著下一小節將運用此結果，進行模擬測試。

# 4 模擬研究

## 4.1 假設

在 3.3 小節提到我們使用最小平方法來估計模型之參數 $\beta$，因此在進行模擬之前，必需先定義殘差及因變數符合一般古典的線性模型之假設：

(1).$cov(e_t, e_{t-s}) = 0, \forall s \neq 0$ 殘差間無自我相關 (non-autocorrelation)。

如果殘差存在自我相關時，迴歸係數的估計值有可能被高估。

(2). $e_t \sim_{iid} N(0, \sigma^2)$，其中 $\sigma^2$ 為一個固定的常數。

(3). $cov(e_t, x_{it}) = 0, \forall i$ 因變數與殘差之間無相關性 (orthogonality)。

殘差必須要滿足同質變異，並且若因變數與殘差之間存在相關性，乃是造成殘差間自我相關的原因之一。

## 4.2 目的

國立中興大學

首先先看下圖，

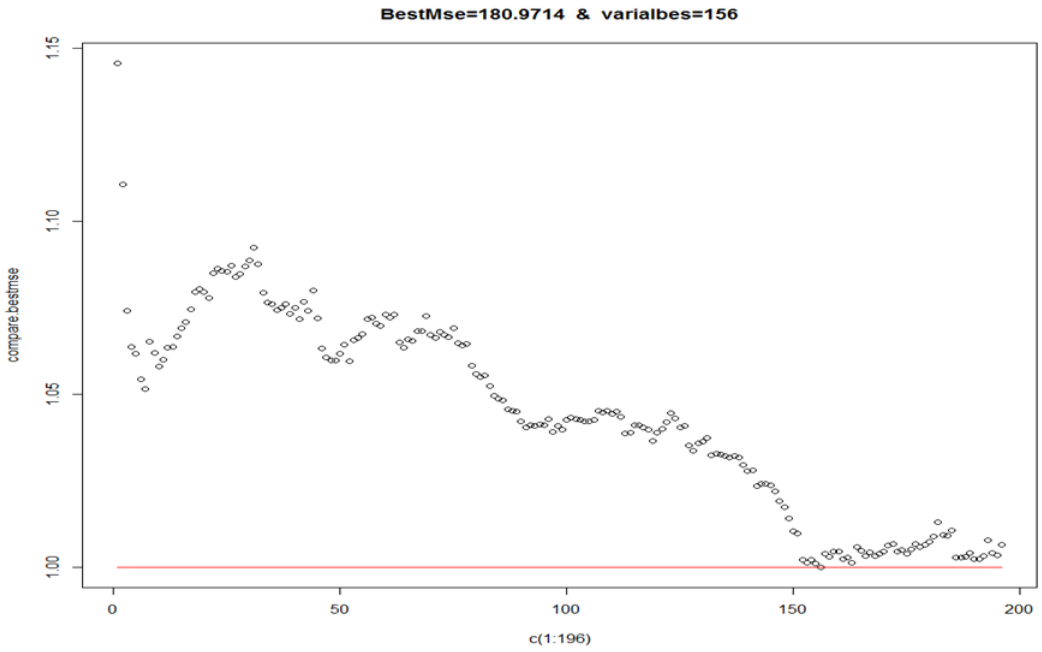



圖 8: 透過 OGA 法逐步選擇變數時，均方誤差之變化情形

由圖 8 可以觀察到，當選擇到第七個變數時，均方誤差便達到了第一個低點，其中這七個變數分別為：大里 Lag1、相對溼度 Lag1、NO2 Lag1、馬祖 Lag1、

O3 Lag1、Lag2、風速 Lag2。因此在此章節，將透過使用 OGA 法所選擇出的前七個變數建立模型，並將此模型假設為模擬實驗中之真實模型，接著生成此七個變數之模擬變數與其他沒有選擇的變數，最後使用上一小節所提到的三種變數選擇方法，藉此實驗結果觀察是否依然透過正交貪婪法選擇出的變數，建立出來的模型其預測誤差會最小。

## 4.3 生成資料

- 以下我們將敘述如何依據實際資料之分析與估計，來建立一個模擬程序。

Step1:

由上述均方誤差達到第一個低點的七個變數，建立一個迴歸模型：假設 n 為變數個數，i 為變數 X 之個數，$p_i$ 為落後期數，$x_i \sim AR(p_i)$，

$$X_{i(t+1)} = \hat{\varphi}_i + \hat{\phi}_1 X_{it} + \hat{\phi}_2 X_{i(t-1)} + ... + \hat{\phi}_{p_1} X_{i(t-p_i+1)} + e_{i(t+1)}$$

並且假設 $PM_{2.5}$ 之真實模型為

$$\begin{aligned} Y_{t+1} = \hat{\beta}_0 + \hat{\beta}_1 Y_{t-1} + \hat{\beta}_2 X_{1(t-1)} + \hat{\beta}_3 X_{2(t-1)} + \hat{\beta}_4 X_{3(t-1)} + \hat{\beta}_5 X_{4(t-1)} \\ + \hat{\beta}_6 X_{4(t-2)} + \hat{\beta}_7 X_{5(t-2)} + \epsilon_{Y_{t+1}} \end{aligned}$$

Step2:

透過 Step1 將 $X_i$ 與 $Y$ 對應之殘差取出，建立一個殘差矩陣 E:

$$E = \begin{pmatrix} \epsilon_{y_1} & e_{11} & \cdots & e_{51} \\ \epsilon_{y_2} & e_{12} & \cdots & e_{52} \\ \vdots & \vdots & \ddots & \vdots \\ \epsilon_{y_n} & e_{1n} & \cdots & e_{5n} \end{pmatrix}$$

Step3:

接著使用有母數拔靴法 (parametric bootstrap method) 對殘差矩陣 E 來進

行抽後放回之抽樣 (sampling with replacement)，借此建立模型來模擬變數。假設第一次從殘差矩陣 E 中抽出的殘差為 $(\epsilon_{Y_i}, e_{1i}, e_{2i}, e_{3i}, e_{4i}, e_{5i})$，則 $X_1, ..., X_5, Y$ 分別為

$$X_{11}^* = e_{1i} \ , X_{21}^* = e_{2i} \ , X_{31}^* = e_{3i} \ , X_{41}^* = e_{4i} \ , X_{51}^* = e_{5i}$$
$$Y_1^* = 0$$

接著假設第二次從殘差矩陣 E 中抽出的殘差為 $(\epsilon_{Y_{i+1}}, e_{1(i+1)}, e_{2(i+1)}, e_{3(i+1)}, e_{4(i+1)}, e_{5(i+1)})$，則 $X_1, ..., X_5, Y$ 分別為

$$X_{12}^* = \hat{\varphi}_1 + \hat{\phi_{11}} X_{11}^* + e_{1(i+1)} \ , X_{22}^* = \hat{\varphi}_2 + \hat{\phi_{21}} X_{21}^* + e_{2(i+1)},$$
$$X_{32}^* = \hat{\varphi}_3 + \hat{\phi_{31}} X_{31}^* + e_{3(i+1)} \ , X_{42}^* = \hat{\varphi}_4 + \hat{\phi_{41}} X_{41}^* + e_{4(i+1)},$$
$$X_{52}^* = \hat{\varphi}_5 + \hat{\phi_{51}} X_{51}^* + e_{5(i+1)} \ ,$$
$$Y_2^* = 0$$

到三次從殘差矩陣 E 中抽出的殘差為 $(\epsilon_{Y_{i+2}}, e_{1(i+2)}, e_{2(i+2)}, e_{3(i+2)}, e_{4(i+2)}, e_{5(i+2)})$，則 $X_1, ..., X_5, Y$ 分別為

$$X_{13}^* = \hat{\varphi}_1 + \hat{\phi_{12}} X_{12}^* + e_{1(i+2)} \ , X_{23}^* = \hat{\varphi}_2 + \hat{\phi_{22}} X_{22}^* + e_{2(i+2)},$$
$$X_{33}^* = \hat{\varphi}_3 + \hat{\phi_{32}} X_{32}^* + e_{3(i+2)} \ , X_{43}^* = \hat{\varphi}_4 + \hat{\phi_{42}} X_{42}^* + e_{4(i+2)},$$
$$X_{53}^* = \hat{\varphi}_5 + \hat{\phi_{52}} X_{52}^* + e_{5(i+2)} \ ,$$
$$Y_3^* = \hat{\beta}_0 + \hat{\beta}_1 Y_1 + \hat{\beta}_2 X_{12} + \hat{\beta}_3 X_{22} + \hat{\beta}_4 X_{32} + \hat{\beta}_5 X_{42}$$
$$+ \hat{\beta}_6 X_{41} + \hat{\beta}_7 X_{51} + \epsilon_{Y(i+2)}$$

Step4:

透過 (10) 與 (11) 可以得到一組 $Y^*, X_1^*, ..., X_7^*$ 的 1500 筆資料，接著去除前面兩百筆資料，以減少初始假設其值為誤差項以及 0 之影響。

Step5:

執行上述步驟一次，便有一組 $Y^*, X_1^*, ..., X_7^*$ 的 1300 筆資料，並用此組資料去模擬真實模型:

$$Y_{t+1}^* = \hat{\beta}_0 + \hat{\beta}_1 Y_t^* + \hat{\beta}_2 X_{1t}^* + \hat{\beta}_3 X_{2t}^* + \hat{\beta}_4 X_{3t}^* + \hat{\beta}_5 X_{4t}^* + \hat{\beta}_6 X_{5(t-1)}^* + \hat{\beta}_7 X_{4(t-1)}^*$$

其中 $\hat{\beta}_0, ..., \hat{\beta}_7$ 為上述生成的七個變數，對 $y^*$ 作迴歸所得到的截距項與係數。

首先為了確保模擬出來的變數正確的近似真實變數，將重複執行上述的步驟 1000 次，並取其平均來觀察是否是正確的模擬，其結果如下表。

| 模型 | $\beta_0$ | $\beta_1$ | $\beta_2$ | $\beta_3$ |
|---|---|---|---|---|
| 真實 | 18.60823 | 0.4405558 | -0.3390602 | 0.6625342 |
| 模擬 | 18.10254 | 0.4354838 | -0.338552 | 0.6635407 |
| | $\beta_4$ | $\beta_5$ | $\beta_6$ | $\beta_7$ |
| 真實 | 0.07182691 | 0.2837861 | 2.623812 | -0.1525464 |
| 模擬 | 0.07171920 | 0.2811893 | 2.605297 | -0.1520955 |

表 6: 比較真實選取變數模型與模擬選取變數模型之係數。

並且為確保生成之變數分別屬於 AR(1) 與 AR(2)，隨機從 $x_1^*, x_2^*, ..., x_7^*$ 這 7 個變數中各抽一個 AR(1) 變數與 AR(2) 變數，觀察其 acf(autocorrelation function) 與 pacf(partial autocorrelation function)，如下圖。

國立中興大學
National Chung Hsing University

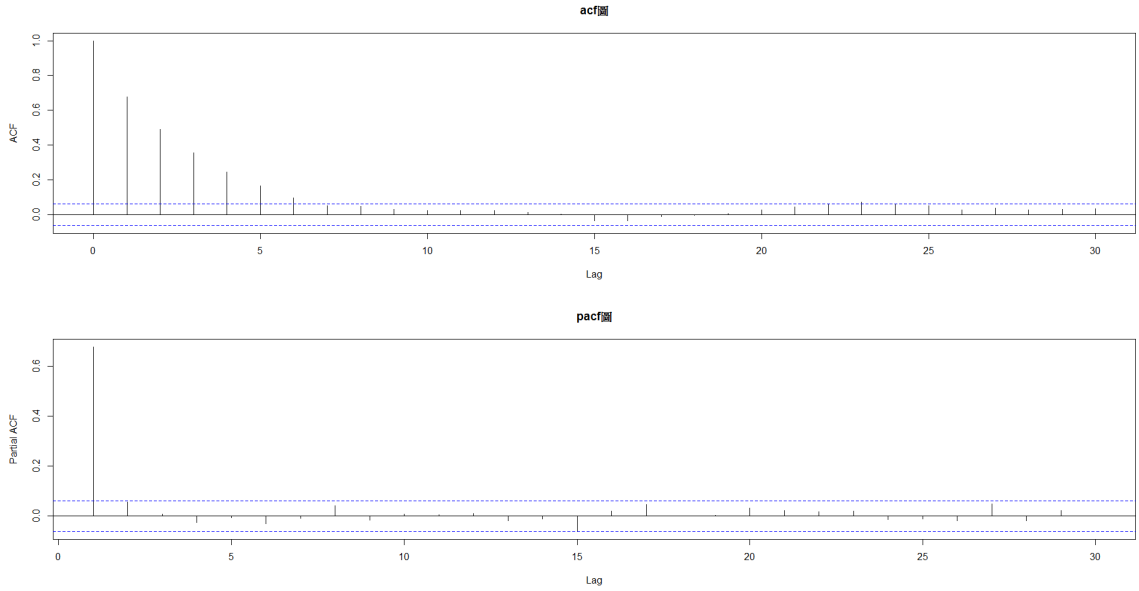



圖 9: 隨機抽出 AR(1) 變數之 acf 與 pacf 圖。

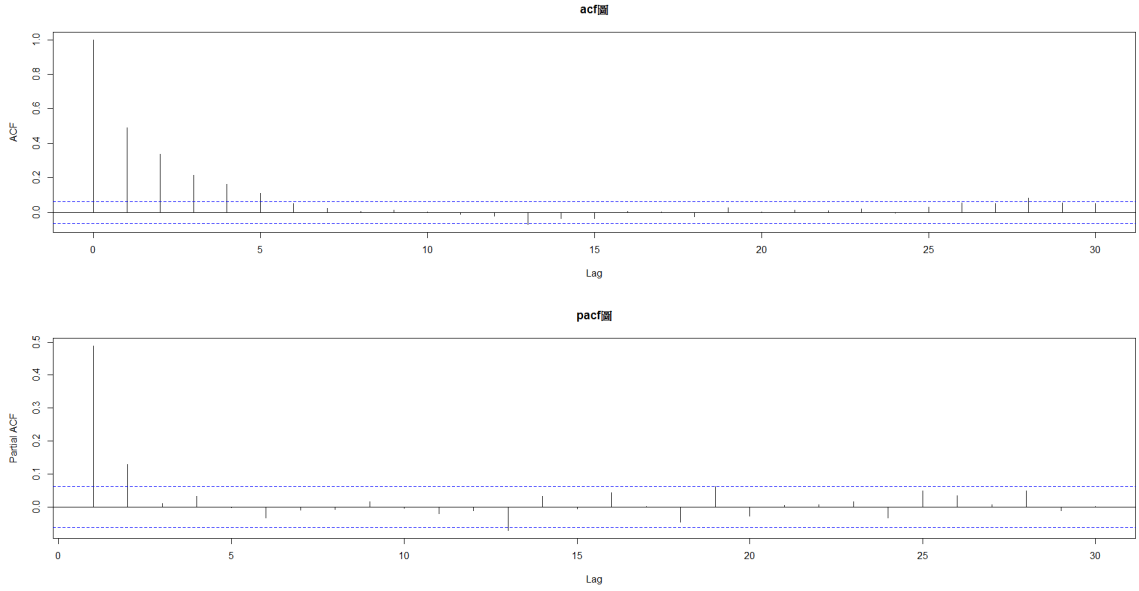



圖 10: 隨機抽出 AR(2) 變數之 acf 與 pacf 圖。

- 模擬未選取變數

由於上述只生成了假設與真實模型有關的變數，其他的變數並未未列入考慮，然而這些與假設的真實模型無關的變數，在加入預測模型之後，是否只會使得預測精準度下降？亦或是其中某些變數會提升預測模型的精準度？因此本文在此將這些未選取的變數一一生成，並在下一小節，透過三種變數選擇方法進一步加以觀察，並求出結論。

Step1:

首先在給定最大落後期數為 10 期之下，配適出每個變數之 AR 模型，限制最大落後期數主要可以降低所有變數之數量，進而減少模擬實驗所需花費的時間。

定義未選取之變數為 $X_k \sim AR(p_k)$，在此 k 為未選取之變數個數，p 為落後期數。未選取變數模型如下:

$$X_{1(t+1)} = \hat{\varphi_1} + \hat{\phi_{11}} X_{1t} + ... + \hat{\phi_{1p1}} X_{1(t-p_1+1)} + e_{1(t+1)} \qquad X_1 \sim AR(p_1)$$

$$X_{2(t+1)} = \hat{\varphi_2} + \hat{\phi_{21}} X_{2t} + ... + \hat{\phi_{2p2}} X_{2(t-p_2+1)} + e_{2(t+1)} \qquad X_2 \sim AR(p_2)$$

$$\vdots$$

$$X_{k(t+1)} = \hat{\varphi_k} + \hat{\phi_{k1}} X_{kt} + ... + \hat{\phi_{kpk}} X_{k(t-p_k+1)} + e_{k(t+1)} \qquad X_k \sim AR(p_k)$$

國立中興大學 National Chung Hsing University

Step2:

透過 Step1 將各個 X 對應之殘差取出，建立一個殘差矩陣 E:

$$E = \begin{pmatrix} e_{11} & e_{21} & \cdots & e_{k1} \\ e_{12} & e_{22} & \cdots & e_{k2} \\ \vdots & \vdots & \ddots & \vdots \\ e_{1n} & e_{2n} & \cdots & e_{kn} \end{pmatrix}$$

Step3:

接著使用有母數拔靴法對殘差矩陣 E 來進行抽後放回之抽樣，藉由抽出的殘差與對應模型之參數來模擬變數，假設第一次從殘差矩陣 E 中抽出的殘差為 $(e_{1i}, e_{2i}, ..., e_{ki})$，則 $X_1, X_2, ..., X_k$ 分別為

$$X_{11}^* = e_{1i} \ , \quad X_{21}^* = e_{2i} \ , \quad ... \ , \quad X_{k1}^* = e_{ki}$$

接著假設第二次從殘差矩陣 E 中抽出的殘差為 $(e_{1(i+1)}, e_{2(i+1)}, ..., e_{k(i+1)})$，則 $X_1, X_2, ..., X_k$ 分別為

$$\begin{aligned} X_{12}^* &= \hat{\varphi}_1 + \hat{\phi_{11}} X_{11}^* + e_{1(i+1)}, \\ X_{22}^* &= \hat{\varphi}_2 + \hat{\phi_{21}} X_{21}^* + e_{2(i+1)}, \\ &\vdots \\ X_{k2}^* &= \hat{\varphi}_k + \hat{\phi_{k1}} X_{k1}^* + e_{k(i+1)} \end{aligned}$$

Step4:

透過 (10) 重複生成可以得到一組 $X_1^*, X_2^*, ..., X_k^*$ 之 1500 筆資料，接著去除前面兩百筆資料，以減少初始假設其值為誤差項以及 0 之影響。

Step5:

執行上述步驟一次，便有一組 $X_1^*, X_2^*, ..., X_k^*$ 的 1300 筆資料，為了確保模擬出來的變數正確的近似真實變數，隨機這些變數中抽出 7 個變數，並用此組資料建立模型:

$$y_{t+1}^* = \hat{\beta}_0 + \hat{\beta}_1 X_{p_1}^* + \hat{\beta}_2 X_{p_2}^* + \hat{\beta}_3 X_{p_3}^* + \hat{\beta}_4 X_{p_4}^* + \hat{\beta}_5 X_{p_5}^* + \hat{\beta}_6 X_{p_6}^* + \hat{\beta}_7 X_{p_7}^*$$

其中 $\hat{\beta}_0, \hat{\beta}_1, ..., \hat{\beta}_7$ 為上述生成的七個變數，對 $y^*$ 作迴歸所得到的截距項與係數。接著重複執行上述的步驟 1000 次，並取其平均來觀察是否是正確的模擬，其結果如下表。

並且為確保生成之變數分別屬於 $AR(p_1)$ 與 $AR(p_k)$，從這些變數中各抽一

| 模型 | $\beta_0$ | $\beta_1$ | $\beta_2$ | $\beta_3$ |
|---|---|---|---|---|
| 真實 | 18.53059 | 45.58437 | -6.35206 | 2.09728 |
| 模擬 | 19.40124 | 42.99549 | -4.86505 | 5.07145 |
| | $\beta_4$ | $\beta_5$ | $\beta_6$ | $\beta_7$ |
| 真實 | 0.565301 | 7.43911 | 5.62924 | 4.07907 |
| 模擬 | -3.348681 | 3.75055 | 6.16734 | 8.01063 |

表 7: 比較真實未選取模型與模擬未選取模型之係數。

個 $AR(p_1)$ 變數與 $AR(p_k)$ 變數，其中 $p_1 = 6, p_k = 10$，觀察其 acf 與 pacf，如下圖。

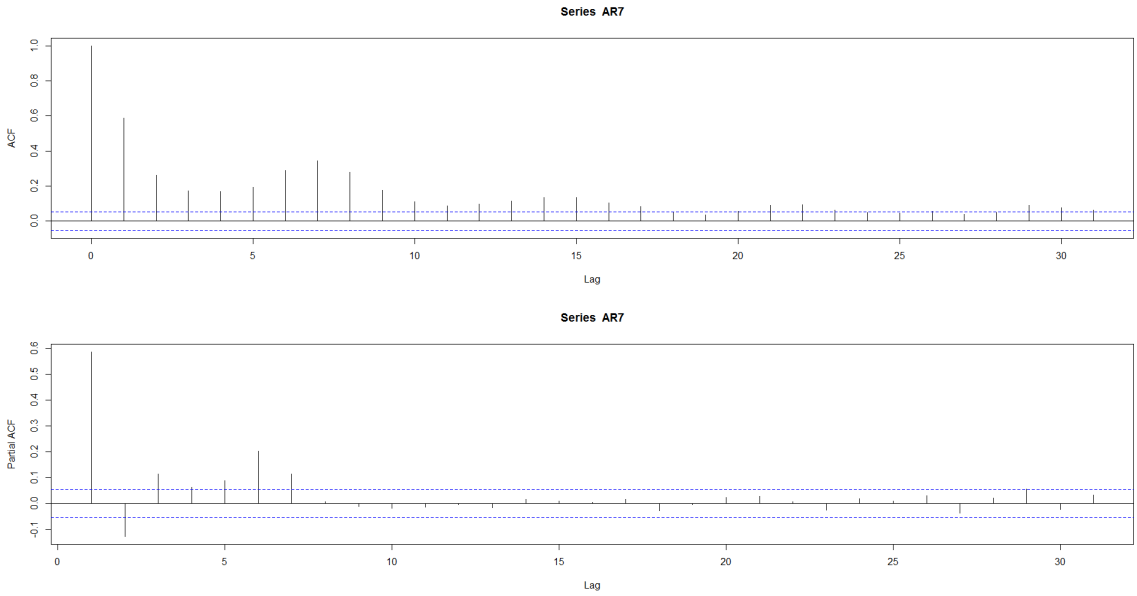



圖 11: 隨機抽出 AR(7) 變數之 acf 與 pacf 圖。

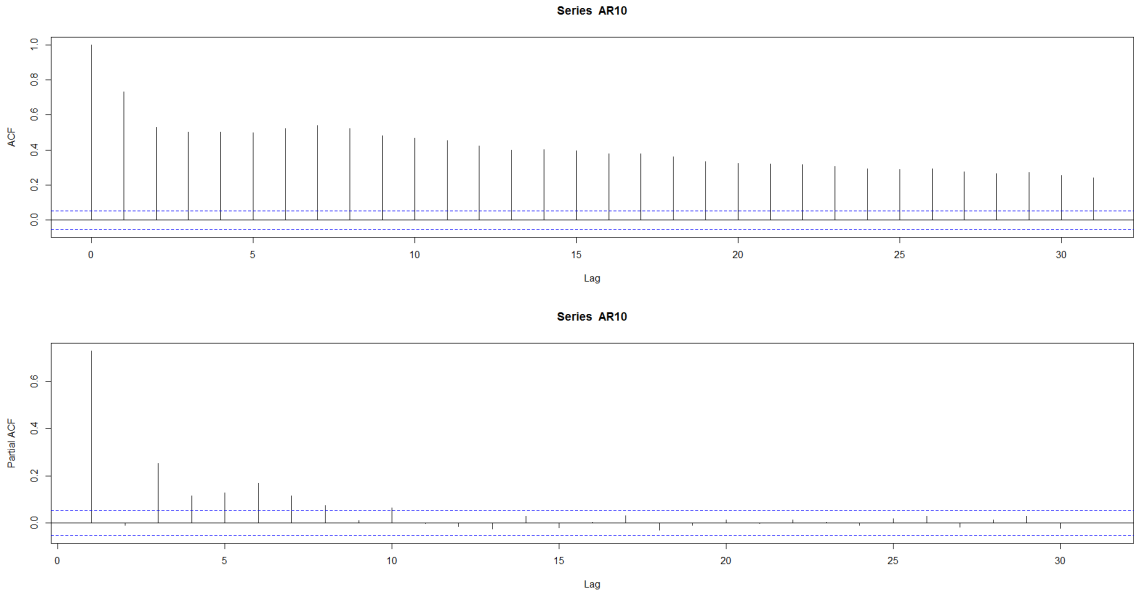



圖 12: 隨機抽出 AR(10) 變數之 acf 與 pacf 圖。

## 4.4 模擬結果

在此使用有母數拔靴法模擬出上述的選取變數與未選取變數，並透過三種變數選擇方法:AIC、BIC、貪婪正交法建立模型並求出其均方誤差，重複執行此實驗五百次，觀察三種變數選擇方法之結果。

- 首先先將每一次實驗三種方法之均方誤差做排名，觀察在這五百次中，三種方法所求出的均方誤差各拿幾次第一名，第二名與第三名。

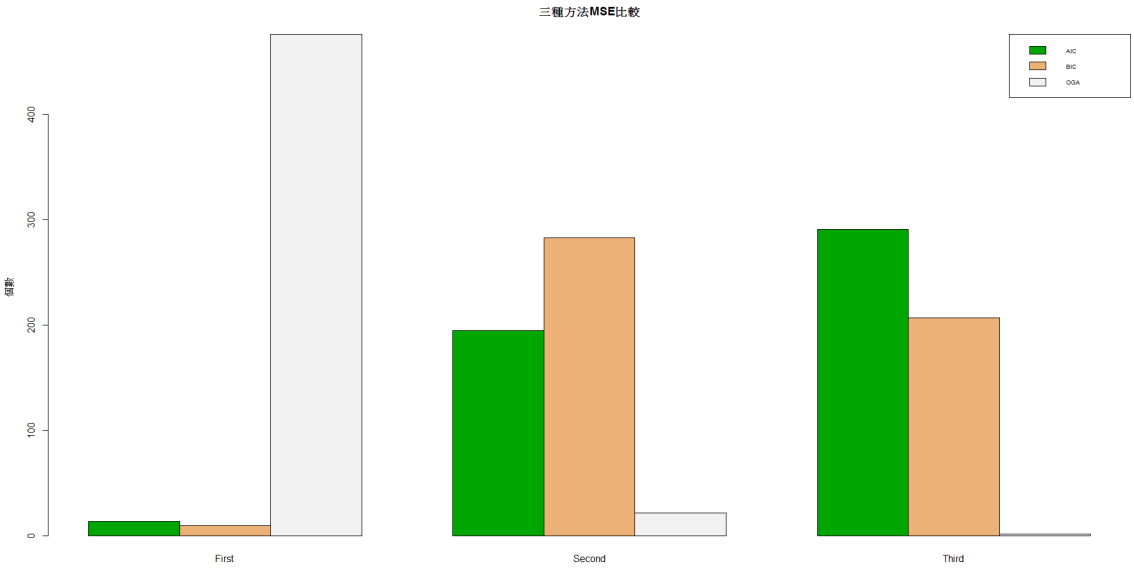


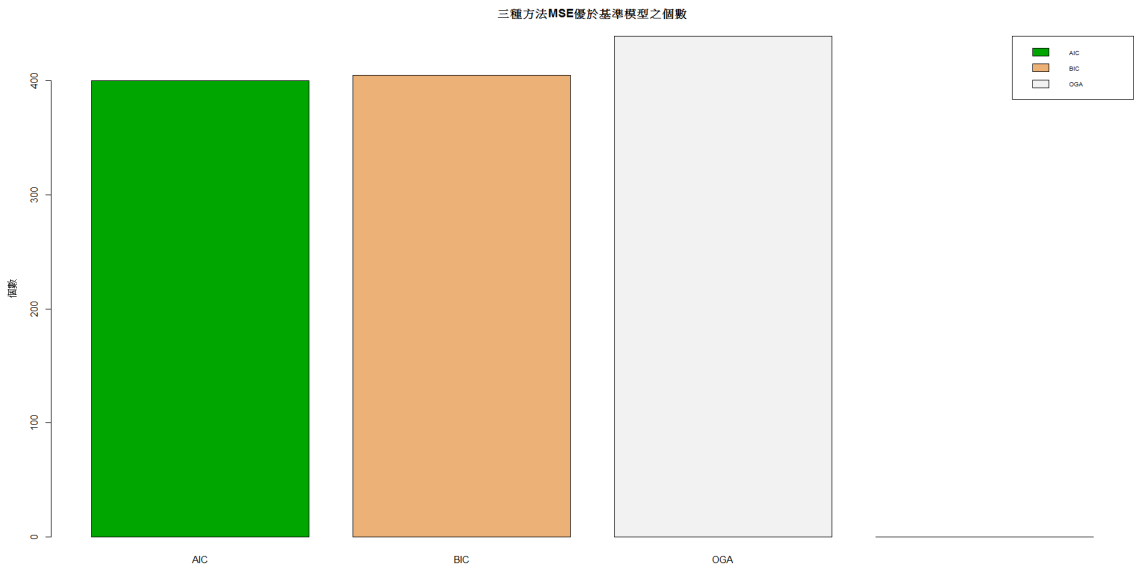

圖 13: 三種方法之均方誤差之排名。

由圖 13 可以觀察出，使用貪婪正交法所得到的均方誤差幾乎每次都是三種方法中最小的，其次是 BIC 最後是 AIC，代表單純就均方誤差來做比較時，貪婪正交法通常會有最精準的預測結果。

- 接著將原始設定的真實模型：

$$y_{t+1} = \alpha + \beta_1 y_t + \beta_2 x_{1t} + \beta_3 x_{2t} + \beta_4 x_{3t} + \beta_5 x_{4t} + \beta_6 x_{5(t-1)} + \beta_7 x_{4(t-1)} + \epsilon_{yt}$$

做為基準模型，並利用此模型計算出均方誤差，最後將三種方法五百次模擬實驗中所得到的均方誤差與其比較，算出比基準模型均方誤差低的次數。




National Chung Hsing University

圖 14: 三種方法均方誤差低於基準均方誤差之次數。

由圖 14 可以觀察出，三種變數選擇方法其均方誤差比基準均方誤差來的低的比例皆有高於 80%，代表單純就變數選擇來說，三種方法求出的均方誤差皆有不錯的表現。

- 再來透過盒鬚圖 (Box-Plot) 來觀察此三種方法在這五百次模擬中，選擇的變數個數所分布的情形。

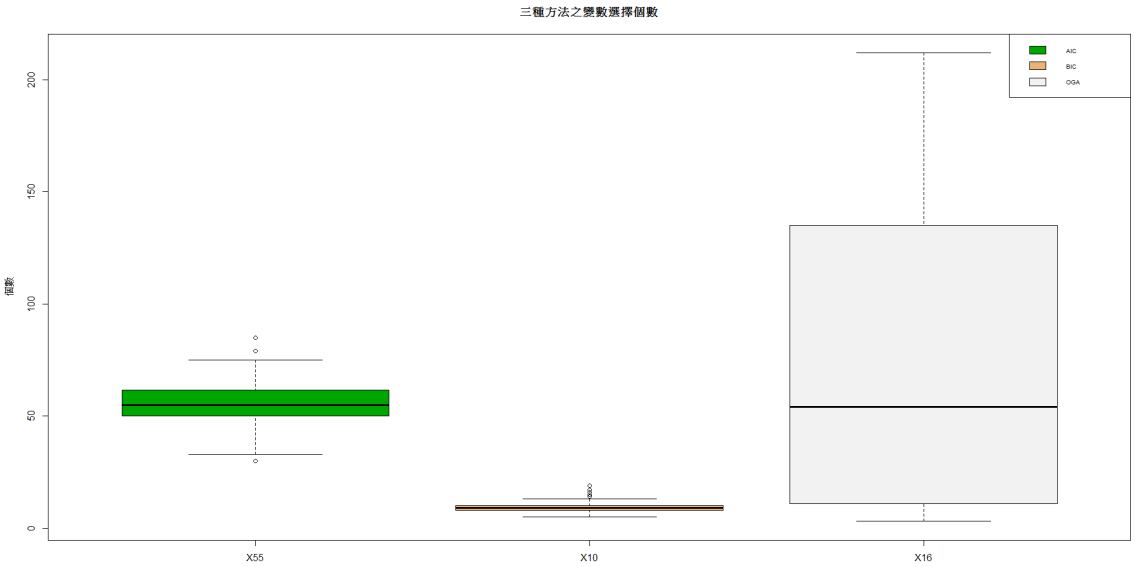



圖 15: 三種方法選擇之變數個數。

National Chung Hsing University

由圖 15 可以很明顯的觀察出，三種變數選擇方法其變數選擇個數差異相當大，AIC 的選擇個數大約都是全部變數的 1/4 左右，BIC 的選擇個數幾乎都分布在 10 個上下，貪婪正交法的選擇個數則分布的很廣，有的時候使用了相當多的變數，但有時選擇的個數比 BIC 還來的少。

# 5 結論

本篇論文的主要目的在於利用三種變數選擇方法：AIC、BIC、貪婪正交法(orthogonal greedy algorithm)，從眾多的變數中去選取出對於想要預測的資料較有影響的變數，進而建立出預測模型，從中選擇出預測誤差最低的預測模型，以得到良好的預測結果。經過多次使用有母數拔靴法來模擬觀測資料，並進一步透過均方誤差比較這三種變數選擇方法所建立的預測模型，可以發現在這三種變數選擇方法中，使用貪婪正交法做為變數選擇的方法在這多次模擬結果中，幾乎每一次的預測誤差都是最小。而在前述介紹 BIC 時便可以得知，由於 BIC 有加上一個而變數個數的懲罰項，故 BIC 每一次選擇出來的變數幾乎都是三種變數選擇方法中最少的，但在少數的模擬結果中，貪婪正交法不但均方誤差是三種方法中最小的，而且所選擇出的變數個數也是最少的，可見貪婪正交法是一個相當出色的變數選擇方法。不過 BIC 雖然其預測誤差比貪婪正交法高，但若是需要使用較少的變數來建立預測模型時，BIC 則會是比較理想的方法。

國立中興大學 National Chung Hsing University

在進行分析時，各種資料的蒐集跟整裡是非常花費時間的工作，本篇論文只取了 2011 ～ 2014 共四年的資料來處理，如果能夠使用更多的資料，預測出來的結果應該會更加精準。而在變數的選擇方法上，除了本篇論文使用的三種方法外，未來可以使用更多其他的方法，如：PCA，以及其他種類型的資料加以比較，想必可以得到更多不同的結論。最後則是當加入了與假設的真實模型無關的變數進入預測模型之後，部分的變數造成預測誤差上升的結果是可以預期的，但某些無關的變數加入預測模型後卻會使得預測結果更加準確，這個現象值得未來繼續探討研究。

# 參考文獻


[ 1 ] Hurvich,C.M. & Tsai,C.L. (1989). Regression and time series model selection in small samples. *Biometrika* **76**, 297-307.

[ 2 ] Ing,C.K. & Lai,T.L. (2011). A stepwise regression method and consistent model selection for high-dimensional sparse linear models. *Statistica Sinica* **21**, 1473-1513.

[ 3 ] Kreiss,J.P. & Lahiri,S. (2012). Bootstrap methods for time series. *Handbook of Statistics: Time Series Analysis: Methods and Applications.* **30**, 1-9.

[ 4 ] Linhart,H. & Zucchini,W. (1986). Finite sample selection criteria for multinomial models. *Statistische Hefte* **27**, 173-178.

[ 5 ] Neath,A.A. & Cavanaugh,J.E. (2012). The Bayesian information criterion: background, derivation, and applications. *Wiley Interdisciplinary Reviews: Computational Statistics* **4**, 199-203.

[ 6 ] Pope III,C.A., Burnett,R.T., Thun,M.J., Calle,E.E., Krewski, D., Ito,K., & Thurston,G.D.(2002). Lung cancer, cardiopulmonary mortality, and long-term exposure to fine particulate air pollution. *Journal of the American Medical Association* **287**, 1132-1141.

[ 7 ] Stute,W., Manteiga,W.G. & Quindimil,M.P. (1993). Bootstrap based goodness-of-fit-tests. *Metrika*, **40**, 243-256.

[ 8 ]Tai,A.P., Mickley,L.J. & Jacob,D.J. (2010). Correlations between fine particulate matter ($PM_{2.5}$) and meteorological variables in the United States: Implications for the sensitivity of $PM_{2.5}$ to climate change. *Atmospheric Environment* **44**, 3976-3984.

[ 9 ] Temlyakov,V.N. (2000). Weak greedy algorithms [*] This research was supported by National Science Foundation Grant DMS 9970326 and by ONR Grant N00014-96-1-1003. *Advances in Computational Mathematics* **12**, 213-227.


國立中興大學 National Chung Hsing University

[ 10 ] Voukantsis,D., Karatzas,K., Kukkonen,J., Räsänen,T., Karppinen,A. & Kolehmainen,M. (2011). Intercomparison of air quality data using principal component analysis, and forecasting of PM 10 and PM 2.5 concentrations using artificial neural networks, in Thessaloniki and Helsinki. *Science of the Total Environment.* **409**, 1266-1276.

[ 11 ] 銀慶剛 (2015) 正交貪婪演算法與高維迴歸模型選取. 自然科學簡訊第二十七卷第四期, 154-158.

[ 12 ] 楊奕農 (2009) 時間序列分析: 經濟與財務上之應用 (二版). 臺北市: 雙葉書廊.

[ 13 ] 吳嘉馨 (2008) 高維度共變異矩陣之推估及其應用. 中央大學統計研究所學位論文, 1-52.

國立中興大學
National Chung Hsing University